

文章编号:1005-0930(2025)01-0024-016 中图分类号:U44 文献标识码:A
doi:10.16058/j.issn.1005-0930.2025.01.003

桥梁高空构件螺栓病害小样本快筛识别 与可视化定位方法

朱彦洁, 陈韬宇, 王瑜晨, 熊文
(东南大学交通学院桥梁工程系, 江苏南京 210096)

摘要:为了实现桥梁高空构件的高效检测及病害的快速识别与精准定位,提出了一种基于无人机和深度学习的小样本桥梁螺栓病害识别算法。通过无人机在桥梁可达性较差的区域进行定制化航线采集,获取固定姿态、角度和距离的表观图像,保障数据的时序可分析性。针对桥梁螺栓的锈蚀问题,基于 YOLOv8 模型提出一种适用于小样本情况下的病害识别方法。多种基线模型对比实验结果表明:该算法在小样本条件下具有优异的性能,识别精度超过 90%。结合图像采集的定位信息与桥梁三维数字模型,实现了螺栓病害的三维可视化定位。该方法为桥梁高空难以到达区域的检修养护提供了高效解决方案,有助于保障桥梁的长期服役与安全耐久。

关键词:桥梁工程;数字桥梁;高空构件;螺栓锈蚀;病害识别;小样本学习;无人机;可视化定位

随着桥梁服役年限的增加,钢结构桥梁螺栓连接位置的病害显著加剧,尤其是在钢桁架等可达性较差的构件。螺栓作为连接和固定这些构件的重要部件,其状态直接影响到整个桥梁结构的安全性。长期暴露在空气、水和盐分等腐蚀介质中,螺栓极易发生锈蚀,导致其承载能力和连接性能下降,甚至引发结构失效和桥梁坍塌的严重后果。因此,如何快速精准识别螺栓锈蚀等病害成为桥梁管养领域亟需解决的问题。

目前,对于螺栓病害,主要依赖人工巡检等传统检测方法,这对于钢桁架等可达性较差的高空构件,往往需要封闭车道,不仅影响交通,而且成本高、效率低。此外,人工巡检还存在人员安全风险和主观判断误差^[1]。因此,高空桥梁构件的表观病害识别一直是日常检测的薄弱环节。为了解决这一问题,基于无人机的桥梁表观病害非接触检测方法逐渐成为研究热点^[2-3]。无人机通过高空拍摄,利用摄像头捕捉桥梁表观图像,并通过机器视觉等方法进行病害识别。相较于传统的人工巡检,无人机具有覆盖范围广、采集速度快和成本较低等诸多优势。因此,基于无人机的桥梁表观病害图像采集和处理技术得到了广泛发展^[4-6]。

在病害的非接触检测中,图像识别算法是核心技术。现有的深度学习模型通过大量桥梁表观病害图像训练,能够自动从原始数据中提取高层次的病害特征,实现精准识别。例如,冯东明等^[7]基于倾斜摄影技术所建立的三维模型对无人机桥梁病害巡检航线进行规划,实现了悬索桥主缆表观病害的定点拍摄和精准识别;余加勇等^[8]建立了病害识别模型并对由无人机采集到的高清图像进行识别,从而实现病害识别;Ye 等^[9]建立了 11 000 张图像的数据集来训练神经网络模型以实现病害检测。在螺栓锈蚀等病害的识别方面,阳茜汕等^[10]基于无人机采集的图像数据建立了螺栓识别深度学习模型,有效地识别了钢桁架结构中的螺栓;沈浩等^[11]提出了一种基于迁移学习的钢桁架桥螺栓病害智能识别方法,满足了工程应用的精度要求;房志恒等^[12]提出了基于修正模型的钢桁架桥螺栓病害识别方法,将螺栓病害识别的正确率提高至 90%。然而,这些方法在实际工程中常面临样本数量不足的问题。为了实现方法的快速拓展及工程应用,提高模型的泛化能

收稿日期:2024-04-26; 修订日期:2024-10-24

基金项目:国家自然科学基金项目(52108118, 52378135); 江苏省重点研发计划项目(BE2021089)

作者简介:朱彦洁(1994—),女,博士,副教授.E-mail:yanjie@seu.edu.cn

通信作者:熊文(1982—),男,博士,教授.E-mail:wxiong@seu.edu.cn

力,使其在小样本情况下也能展现较高的识别精度显得尤为重要。基于小样本的检测方法通过减少对大规模训练数据的依赖,能够在样本较少的情况下依然保持较高的检测精度。这不仅降低了检测成本,还提高了检测的灵活性和效率。然而,目前较少研究针对螺栓锈蚀识别方法的小样本识别方法。

此外,目前病害识别方法多集中在提高病害的检测精度和速度^[13-14]。例如,Chen 等^[15]采用数据增强和滑动窗口技术提高了裂缝识别的精度;冯东明等^[7]提出通过图像融合扩充数据集并采用 Faster-RCNN 模型,该方法平均精度可达 72.3%。Dung 等^[16]利用特征迁移学习显著提高了模型的检测精度;Yu 等^[17]提出 YOLOv4-FPM 模型,利用 Focal Loss 对损失函数进行优化,从而提高了病害检测精度;柴雪松等^[18]提出基于深度神经网络的混凝土表观病害识别算法,解决了病害识别速度慢的问题。然而,这些方法忽视了病害位置的重要性。实际上,病害位置对桥梁养护工作具有重要指导意义。不同结构形式的桥梁、不同位置的病害,其处置措施存在显著差异,位置的缺失可能导致决策盲目和维修低效。特别是对于螺栓锈蚀等隐蔽性强、聚集性显著的病害,其定位难度更大。然而,目前少有研究关注病害定位问题。

目前,螺栓病害识别方法均需要较大的样本数量,难以在实际工程中快速应用。此外,现有病害识别方法多忽视病害的实际位置,使得针对性的管养和维护难以进行。为了解决这些问题,基于 YOLOv8 模型,提出了螺栓锈蚀的小样本识别算法;结合无人机和空间信息技术,提出病害可视化定位方法,实现了对于可达性较差的螺栓病害的高效识别和精准定位。

1 基于无人机定航的桥梁高空病害小样本识别与定位方法

为解决桥梁高空构件日常检测难题,提出一种基于无人机定航采集和改进 YOLOv8 模型的桥梁非接触表观检测方法,实现表观图像采集、病害小样本识别和病害可视化定位方法,具体方法流程见图 1。

1.1 基于无人机的桥梁表观图像采集方法

利用无人机对桥梁表观病害图像进行采集过程中,要在保证无人机飞行安全的前提下,对人工难以直接巡检的特殊部位进行拍摄,并满足图像处理的相关指标^[19]。根据待检测桥梁的管养需求,结合现场实际工程条件,针对图像信息采集设备、图像信息采集参数以及图像信息采集耗时问题,提出一套无人机设备选择流程(图 2)。

多旋翼无人机凭借其紧凑的机身,使其具备在复杂空间飞行及稳定拍摄检测能力。综合对比后采用大疆 M300RTK 并搭载禅思 H20T 变焦镜头,进行桥梁表观图像采集。通过明确待检测病害分布在桥梁中的位置,确定无人机定检航线,并将结果写入无人机路径文件,从而导入无人机执行病害定检任务。

1.2 基于改进 YOLOv8 的螺栓病害识别模型

由于螺栓锈蚀病害数据集样本量较小,因此选择 Pascal VOC 数据集作为初始训练以获取预训练的权重^[20],利用迁移学习使用预训练权重辅助进行螺栓病害的识别学习。基于 YOLOv8 模型^[21],并结合小目标检测层、Focus 层和 Bottleneck CSP 模块,实现螺栓病害的小样本学习,模型架构如图 3 所示。

1.2.1 小目标检测层 采用无锚点方法,通过分解为分类和

回归两个子任务,从而直接预测目标框的位置和尺寸,减少锚点设计的复杂性,降低计算成本。其重点关注部分为待检测目标的核心区域,即中心位置和边界位置。通过计算预测位置到真实边界的距离,以获取预测目标的方位信息。节点中心度的计算式为

$$C = \sqrt{\frac{\min(l, r)}{\max(l, r)} \times \frac{\min(t, b)}{\max(t, b)}} \quad (1)$$



图 1 桥梁非接触表观检测方法流程

Fig.1 Flow chart of non-contact apparent inspection methods for bridges

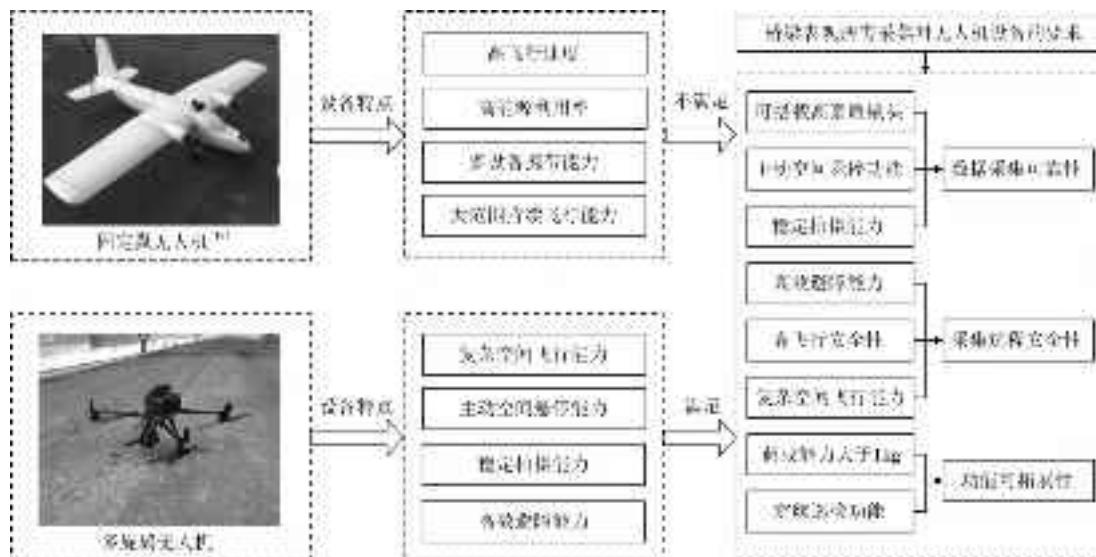


Fig.2 UAV equipment selection process

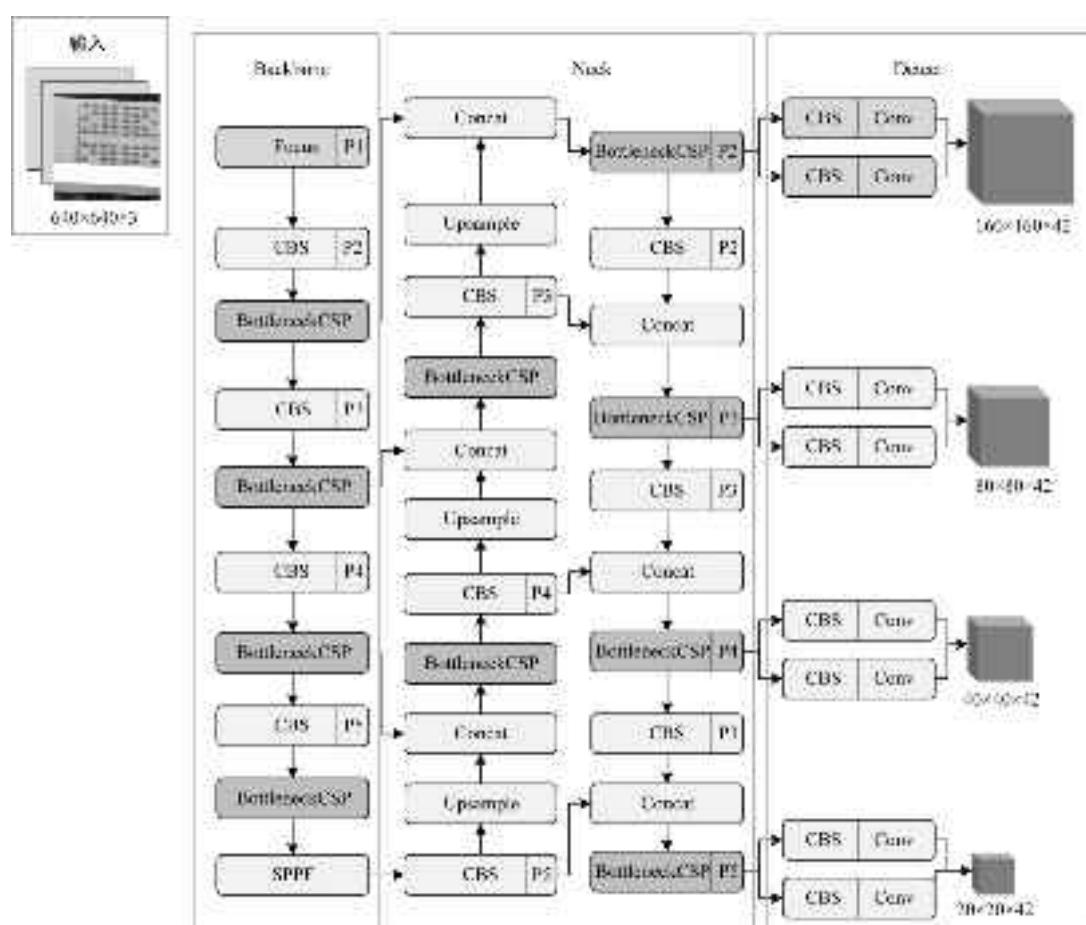


Fig.3 Improved YOLOv8 model framework

式中: l, r, t, b 分别为图像中位置点到真实目标的左、右、上、下边界的距离。在边框回归训练中,中心度用于衡量检测点与目标中心的距离,距离越远的点中心度越低,这可能导致回归误差增大。

YOLOv8 的原始结构中每个检测层均设计了固定尺寸的 3 种锚定框,但固定尺寸限制了其对较小目标的判定能力。因此,增加了一层专门用于小目标检测的层,以更有效地提取分辨率较低的图像信息,从而在复杂场景下实现对小目标(如早期锈蚀)的精准识别,进而提升模型整体的识别精度。

1.2.2 Focus 层 Focus 结构设计的核心目的是为了在不牺牲重要空间信息的前提下,减少计算的复杂性并提高网络运行效率。Focus 结构将输入图像的分辨率减半,同时增加通道数量。具体操作为将输入图像的每个 2×2 的像素块重新组成一个更深层次的表示。例如,假定一个 2×2 的像素块,每个像素点有 3 个通道,Focus 结构会将这 8 个数值($2 \times 2 \times 3 = 12$ 个数值)重新排列成一个由 4 个通道组成的单像素点,每个通道包含原来 1 个像素点的所有通道信息。这样,原本的图像大小减半,但通道数增加了 4 倍。

1.2.3 BottleneckCSP 模块 由于原有的 C2f 模块耗能较大,因此采用内存使用和计算负荷较少的 BottleneckCSP 模块进行替代。该模块主要用于学习网络中的残差特征,从而提高对于检测目标深层特征的提取能力。两个模块结构对比如图 4 所示,Bottleneck 层的基本结构是在进行 1×1 和 3×3 卷积后,通过短路连接回到自身,这种设计在特征提取阶段减少了计算参数量,在保证推理速度和预测准确性的前提下,有效减小了模型体积,使模型变得更为轻量。

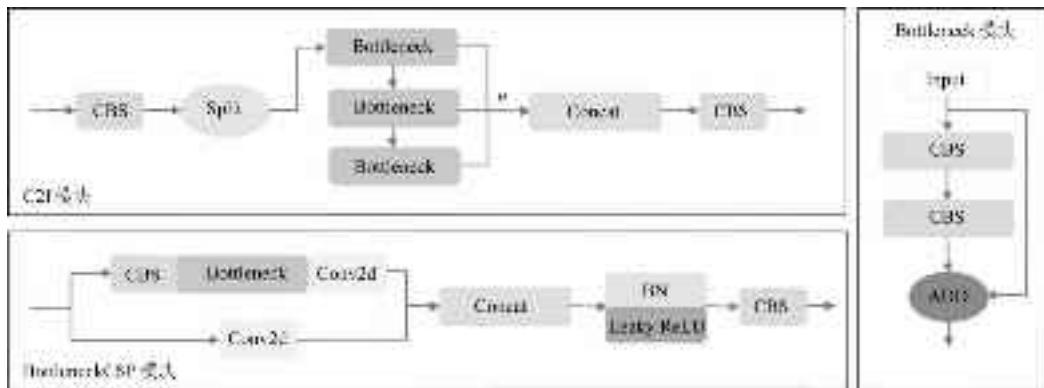


图 4 C2f 模块与 BottleneckCSP 模块的结构对比

Fig.4 Comparison of the structure of the C2f module and the Bottleneck CSP module

1.2.4 模型迁移 尽管 YOLO 算法具有广泛适用性,但在不同的应用场景下,仍然需要根据具体的应用场景进行调整。尤其是在小样本情况下,模型的定制化更为重要^[22]。迁移学习可以很好地满足个性化模型的需求,其基本原理是在大型数据集上预训练模型,并将其参数迁移到新的任务中进行微调,以找到最佳检测权重参数,具体流程如图 5 所示。

首先,利用桥梁螺栓锈蚀病害数据对提出的模型进行多组训练,以确定最佳性能的模型和自适应层;然后,将选取模型的权重信息迁移至网络中,通过逐层解锁和微调模型层,观察模型性能变化,逐步优化模型,保存经过调试的自适应层权重文件,并结合新的数据集进行进一步训练;最终,获得适合桥梁螺栓锈蚀病害小样本检测任务的网络参数的相关权重。通过这一过程,模型能够更好地理解数据之间的复杂关系,实现对桥梁螺栓锈蚀病害趋势的准确预测。

1.3 基于倾斜摄影的桥梁病害可视化定位方法

一般情况下,相机镜头存在视角极限,很难获得全桥的单张图像。对于大跨径桥梁,更是无法仅用单张图像完成对

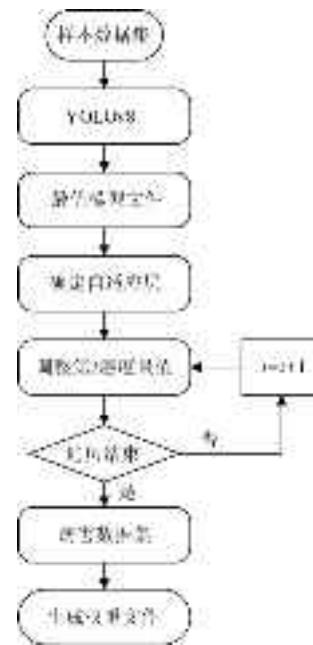


图 5 模型迁移的调参过程

Fig.5 Parameter adjustment process for model transfer

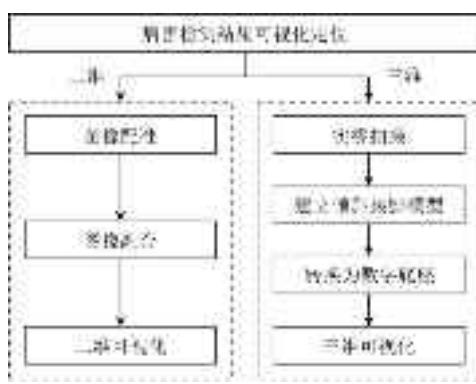


图 6 桥梁病害可视化定位方法

Fig.6 Visualization and localization of bridge damage

全跨信息的采集^[23].如果对大跨径桥梁拍摄多张图像,则可能会出现桥跨关键信息的缺失和模糊.为了解决这个问题,提出了基于图像配准与融合的桥梁病害可视定位方法,优化二维桥梁病害可视化表达;然后,针对桥梁三维可视化应用薄弱的问题,提出基于倾斜摄影技术搭建倾斜摄影模型的病害可视化三维数字底座,并设计图像 GPS 信息处理方法,在进行病害检测前提取图像 GPS 信息,利用坐标融合算法将所存储的 GPS 信息重新载入到检测后的图像中,并将检测结果导入至三维模型;最终,通过 GPS 信息完成病害的自动定位,实现螺栓病害的三维可视化交互.具体方法如图 6 所示.

1.3.1 桥梁病害二维可视化定位方法

由于无人机拍摄

的图片往往只包含待测部位的一小块区域,因此识别之后的图片结果也只包含待检测部位一小块区域的病害识别信息,不能直观地对桥梁病害的位置进行展示,可视化效果差.因此,利用二维平面图像拼接方法,将检测结果在二维全景平面中进行可视化定位,其关键步骤是图像配准和图像融合,前者实现多幅图像的粗对准拼接,后者通过消除光照、拍摄时间等曝光差异产生的拼接痕迹来实现精细拼接.

在图像拼接问题中,最关键的是解决图像旋转问题.针对该问题,采用一种基于特征点旋转归一化的图像配准算法,以提高对图像旋转和小尺度变化的鲁棒性^[24].算法的具体步骤可详细描述如下:

(1) 对参考图像和待配准图像提取 Harris 特征点

基于计算得到的特征点周围邻域旋转归一化参数,采用几何矩的方法实现旋转归一化,减少在特征点匹配过程中由于旋转引起的误匹配,提升图像配准的精确性和鲁棒性.对于一幅灰度图像 $f(x,y)$,其 $p+q$ 阶几何矩 $m_{p,q}$ 的计算式为

$$m_{p,q} = \iint_{\Gamma} x^p y^q f(x,y) dx dy \quad (2)$$

其中: Γ 为图像的支集.图像 $f(x,y)$ 的 $p+q$ 阶中心矩 $\mu_{p,q}$ 的计算式为

$$\mu_{p,q} = \iint_{\Gamma} (x - \bar{x})^p (y - \bar{y})^q f(x,y) dx dy \quad (3)$$

其中: $\bar{x} = m_{1,0}/m_{0,0}$, $\bar{y} = m_{0,1}/m_{0,0}$ 为图像的质心.定义两个张量(tensor) t^1 、 t^2 的计算式为

$$\begin{cases} t^1 = \mu_{1,2} + \mu_{3,0} \\ t^2 = \mu_{2,1} + \mu_{0,3} \end{cases} \quad (4)$$

定义旋转归一化角度计算式为

$$\theta = \arctan(-t^1/t^2) \quad (5)$$

$$t^3 = -t^1 \sin \varphi + t^2 \cos \varphi \quad (6)$$

需要注意的是,该式还定义了另外 1 个张量 t^3 ,这是因为旋转归一化角度公式一般有 2 个解,分别记作 θ 、 $\theta+\pi$,而通过定义的张量 t^3 可以得到唯一的归一化角度,其原理为在 2 个解中只有 1 个能够使 $t^3 > 0$.因此,如果角度 θ 能使得 $t^3 > 0$,则归一化角度为 θ ,否则取旋转归一化角度为 $\theta+\pi$.

旋转归一化角度 θ 相对于质心(\bar{x}, \bar{y})进行计算.

(2) 特征点匹配

对于每个检测到的 Harris 特征点,计算其邻域窗口内的像素差平方和,并进行旋转归一化处理.这一步的目的是在不同旋转角度下保持特征点的一致性,使得特征点的描述符在旋转变换下保持稳定.通过计算特征点邻域窗口的像素差平方和,可以初步提取出潜在的特征点对.

(3) 求解变换矩阵

在得到初步的特征点对后,使用 RANSAC(随机抽样一致性)算法剔除不匹配的特征点对.RANSAC 算法是一种迭代方法,能够在大量数据中识别出内点和外点(即不匹配的特征点对).该算法通过多次随机抽样和

模型拟合,最终保留那些具有一致性的特征点对,并剔除不匹配的点对(外点).该算法通过重复从所有特征点对中随机选取固定数量的样本点来估计变换模型,并计算符合该模型的内点数量,从而选出内点数最多的模型作为最终的图像变换模型,同时剔除不符合模型的外点^[25].通过足次抽样计算,能够以较高的概率确保所得模型及其内点的准确性,确保图像变换的有效性.

(4)根据经过 RANSAC 筛选后的正确匹配的特征点对,计算图像间的几何变换参数,完成图像配准.这一步通过几何变换(如平移、旋转、尺度变换等),将待配准图像调整至与参考图像对齐的位置和角度,从而实现图像的配准.

在图像配准操作结束后,将图像融合为单一图像.采用基于区域的图像融合算法,其具体步骤如下:

1)图像分割.基于像素特征对图像进行分割,计算式为

$$f(x, y) = \begin{cases} 1 & I(x, y) > T \\ 0 & I(x, y) \leq T \end{cases} \quad (7)$$

其中: $I(x, y)$ 为位置 (x, y) 处的像素值.

2)特征提取.对所分割得到的区域进行特征提取,包括区域大小、形状、颜色、纹理特征和边缘信息等,以评估各区域对融合图像的重要程度.

3)采用加权平均融合的区域融合策略,根据区域的重要性给予不同权重,融合结果的计算式为

$$F(x, y) = w_1 I_1(x, y) + w_2 I_2(x, y) \quad (8)$$

其中: I_1 和 I_2 为待融合区域的像素值; w_1 和 w_2 为权重,且相加为 1.

4)融合后处理.融合后的图像一般情况下会存在融合边缘突兀的情况,因此采用高斯滤波,对其进行平滑处理以消除融合边缘,计算式为

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (9)$$

其中: $G(x, y)$ 为高斯滤波核.

1.3.2 桥梁病害三维可视化定位方法 在对桥梁模型三维重建时,无人机采集的航拍图像的质量对模型的重建效果至关重要.图像采集时无人机的航线对图像质量有着决定性影响.因此,需要基于待测桥梁的结构特点和实际环境进行无人机航线规划.

在城市房屋类建筑物的倾斜摄影建模中,无人机飞行航线一般规划为正圆形,对于桥梁这种长宽比巨大的建筑物,一般的正圆形航线不再适用,因此考虑规划可覆盖待重建的桥梁主体的航线.建议航线规划借助 DJI Terra 软件实现.

(1)全桥精细化倾斜摄影建模

得益于多视角三维重建的原理,倾斜摄影克服了传统正射影像只能从垂直角度获取的局限性.其在满足一定的重叠要求的同时,通过从一个垂直角度和多个倾斜角度对同一物体进行多角度图像拍摄,以最终获取完全的物体三维图像^[26].随后,通过数据处理技术,对所采集的影像数据进行三维重建和倾斜摄影建模,从而实现对桥梁的三维模型可视化呈现.

在利用无人机对桥梁图像完成采集后,进行桥梁倾斜摄影模型的建立,建议采用 DJI Terra 和 Context Capture 两种软件对三维模型进行重建,构建较为精细的结构三维模型,以支撑后续的病害定位.

(2)全桥模型的病害精准定位

图像 GPS 信息定位技术可为图像提供精确空间定位,将地理坐标与数字图像特征点进行关联,即可实现精确的结构重建.所生成的三维重建模型可基于其 GPS 信息准确嵌入 GIS(地理信息系统)中,实现病害的可视化.

由于经过深度学习算法识别之后的桥梁病害识别结果图像会失去原图像的地理位置信息,因此必须利用图像 GPS 信息处理技术为结果图像添加 GPS 信息后,才能进行后续的建模和可视化操作.因此,提出基于倾斜摄影模型的图像 GPS 定位信息传递方法,将原图像 GPS 信息进行批量提取,并批量融合到识别结果图像中,然后将图像批量导入倾斜摄影模型中,实现桥梁螺栓锈蚀病害三维空间位置的可视化.

具体方法为:首先,对原图像 GPS 信息进行批量提取,并将提取的 GPS 信息保存为 CSV 文件格式,设置

文件第1列为图片编号,第2列为纬度坐标,第3列为经度坐标,第4列为高度坐标;然后,对桥梁病害识别结果图像进行编号,编号顺序与GPS信息表中的编号顺序保持一致且一一对应;再次,将桥梁病害识别结果图像文件夹与GPS信息表导入软件进行GPS信息融合;最后,将坐标融合完成的包含有原图GPS信息的桥梁螺栓锈蚀病害识别结果图像导入软件,点击相应坐标点,即可查看对应图像的病害识别结果。

2 实例分析

2.1 数据采集

采用的钢桁架桥全长为298.4m,桁架部分高度较高,只能通过桥检登高车进行日常检查,但该桥地处城市主干道,车流量巨大,采用桥检登高车对道路通行状况带来极不利影响,因此对该桥的桁架病害进行检测时,存在可达性低且检查难度高的问题。为此,采用提出的方法进行螺栓病害检测。

表1 相机参数

Table 1 Camera parameters

| 参数类型 | 具体数值 |
|-------------|-------|
| 快门速度 | 1/50 |
| 与被摄物之间的距离/m | 3 |
| ISO | 100 |
| 光圈 | f/3.5 |
| 焦距/mm | 25 |

为保证无人机飞行的安全性和数据传输的稳定性,根据钢桁架桥的结构特点,结合表观病害的行业检测标准,最终选择采用大疆的M300RTK型行业级无人机和禅思H20相机进行实际病害检测。为了保证飞行安全和交通安全,无人机和桥体之间的距离最小为3m。此次检测任务相机参数设置见表1。

2.2 数据集

由于待检桥梁为钢桁架桥,因此待检目标主要为螺栓。将螺栓划分为非锈蚀螺栓和锈蚀螺栓两类。由于锈蚀病害对于螺栓的重要性,因此对于存在锈蚀即算作螺栓锈蚀。为了方便标注,将这两类螺栓记为bolt(无锈蚀螺栓)和corrosion bolt(锈蚀螺栓)。所标注的源对象为无人机采集的桥梁表观图像,并对图像进行筛选,筛选出包含有螺栓部件的图像,共计48张。

采集的每张图像中均含有大量的螺栓部件。然而,由于螺栓尺寸较小、原图像数量较少等因素,直接对原图进行标注会影响训练效果。因此,首先采用滑动窗口对原图进行等步长裁剪,将原图中集中于螺栓板上的螺栓分置于不同的图像中。在满足标注要求条件下设置参数如下:滑动窗口为640×640,步长为320×320。裁剪结束后共得到7920张图像。滑动窗口裁剪的结果图像主要有两类:第1类为不包含螺栓的图像;第2类为包含螺栓的图像。其中,第1类图像对数据集标注以及训练没有用处。因此,需要筛选出第2类图像进行后续标注和训练。最终筛选出500张包含螺栓的图像,图像的部分筛选结果如图7所示。

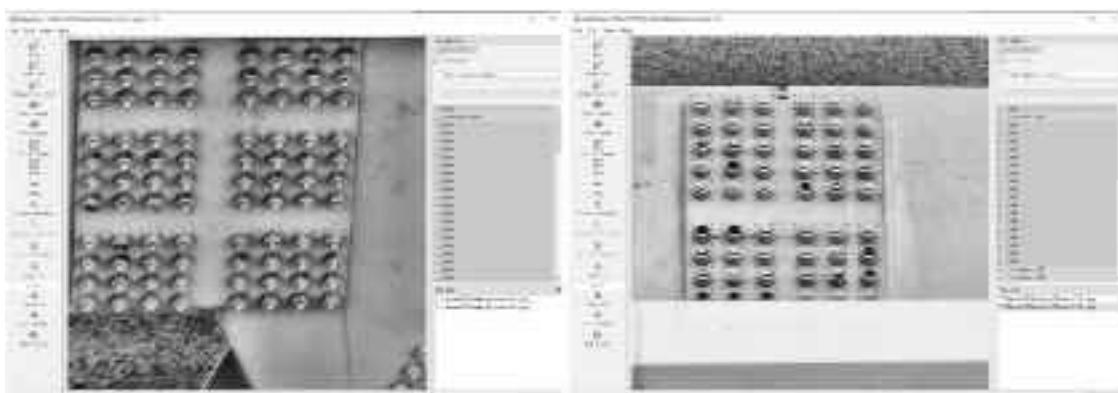


图7 螺栓锈蚀的标注过程

Fig.7 Bolt corrosion labelling process

为研究小样本对目标检测算法模型训练的影响,设置多个不同样本数量的数据集,并根据常用比例划分训练集(70%)、验证集(15%)、测试集(15%),共划分4组,分别为:①第1组500,②第2组450,③第3组400,④第4组350。为了测试过程的严谨,设定测试轮次固定为500,对最终的数据进行非线性拟合,并对最终的精准度和损失进行比较。

如图 8 所示,根据数据集标注框形心位置分布,数据集的标注框形心位置分布都较为均匀;根据数据集标注框尺寸分布,数据集的螺栓尺寸主要集中于 0.1~0.5,为典型的小目标检测,80%以上标注框呈正方形,20%以下标注框呈长宽比不定的矩形.可以看出,该数据集的图片拍摄角度较好,确保了正对螺栓进行拍摄,且体现数据集制作过程中的螺栓标注质量较高.

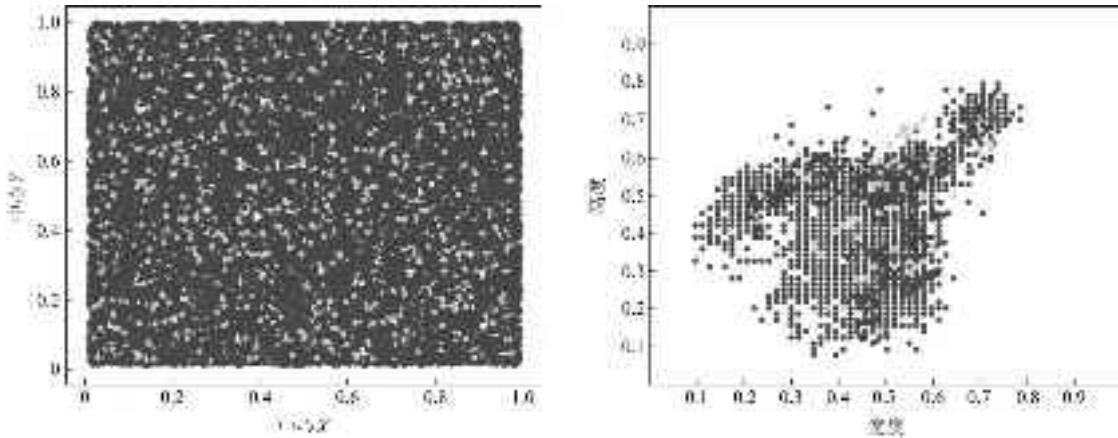


图 8 数据集可视化
Fig.8 Dataset visualisation

2.3 评价指标

评估病害检测模型的性能,通常使用多类别平均精度 (mean Average-Precision, mAP) 作为其测试结果的评价标准.在计算平均精度之前,需要先计算交并比 (IoU)、精确度 (Precision) 和召回率 (Recall) 等指标.其中, IoU 表示系统预测框与实际标记框的重叠程度^[27], 其计算方法为检测结果 (Detection Result) 与真实值 (Ground Truth) 交集的面积除以其并集的面积

$$\text{IoU} = \frac{\text{DetectionResult} \cap \text{GroundTruth}}{\text{DetectionResult} \cup \text{GroundTruth}} \quad (10)$$

精确度指在所有被识别为病害的图片中, 实际正确识别为病害的比例; 召回率指在测试集中所有病害图片中, 被正确识别出来的比例. 具体计算式如下

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (11)$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (12)$$

其中: TP 为被模型识别为正类的正样本; FP 为被模型识别为负类的负样本; FN 为被模型识别为负类的正样本.

提出的模型主要用于识别锈蚀螺栓和非锈蚀螺栓, 即检测目标为两个类别. 因此, 模型性能的综合评估指标可通过计算两个类别的 AP 平均值 (mAP) 来实现, 计算式为

$$\text{AP} = \int_0^1 P(R) d(R) \quad (13)$$

$$\text{mAP} = \frac{1}{\text{classes}} \sum_{i=1}^{\text{classes}} \int_0^1 P(R) d(R) \quad (14)$$

2.4 螺栓病害识别结果

2.4.1 模型有效性分析 为了验证提出模型对于锈蚀螺栓共性特征识别的有效性, 此次用到的测试集样本量为 50. 基于模型在测试集上的结果, 绘制两类检测目标的精准度-召回率曲线(图 9). 未锈蚀螺栓的 AP 值为 0.974, 锈蚀螺栓的 AP 值为 0.894, 全类别 mAP 值为 0.934. 第 2 组未锈蚀螺栓的 AP 值为 0.953 锈蚀螺栓的 AP 值为 0.860, 全类别 mAP 值为 0.907. 根据结果可以看出, 该模型拥有较好的识别效果, 可在仅使用少量标注数据集的情况下实现高精度的病害识别.

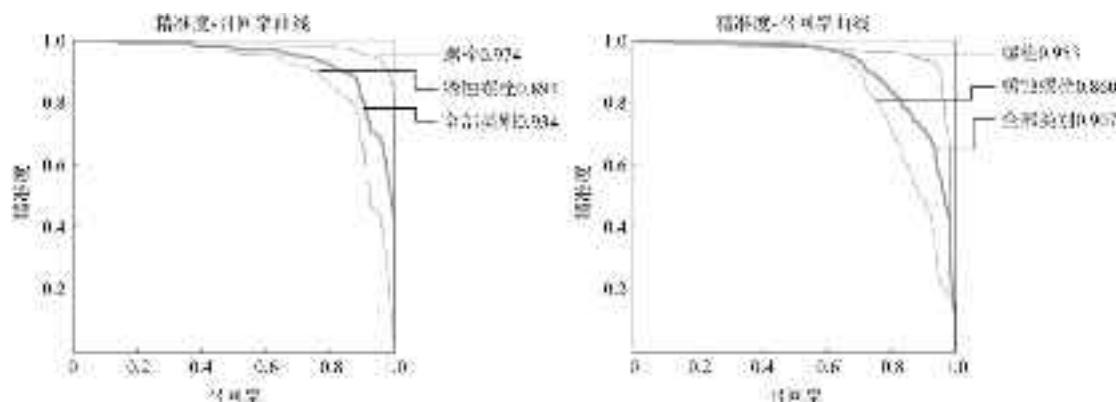


图 9 提出模型的精准度-召回率曲线
Fig.9 Precision-recall curve of the proposed model

2.4.2 与基线模型的对比分析 为了验证提出模型的优越性,将其与 SSD、YOLOv5 和 Faster-RCNN 这 3 个模型进行对比,3 个基线模型介绍如下:

(1) SSD.该模型是一种用于对象检测的深度学习模型.其在单次前向传递过程中生成一系列边界框和类别概率,这使得其比早期两阶段检测器检测速度更快.SSD 可在多个特征图上执行检测,这样可更好地检测不同尺度的对象.

(2) YOLOv5.该模型是 YOLO 系列模型的第 5 个版本,其采用单阶段架构,直接在单个前向传递中预测对象的类别和位置.其能实现更高效的模型架构、数据增强技术和训练策略,使其在许多对象检测任务中表现出色.

(3) Faster R-CNN.该模型是一种两阶段对象检测器,由 Region Proposal Network (RPN) 和 Fast R-CNN 检测网络两部分组成.其将区域建议和检测合并到一个统一的网络中,在保持高精度的同时,提高了检测速度和效率.

训练损失曲线是评估模型训练质量的重要指标.图 10 展示了 4 种模型的训练损失变化情况.由于不同模型的损失函数值范围存在差异,图 10(a)中 Y 轴用于衡量提出的模型和 YOLO 系列网络的损失值,图 10(b)中 Y 轴用于衡量 Faster-RCNN 和 SSD 网络的损失值.YOLO 系列与 SSD、Faster-RCNN 的损失函数不同,导致损失值范围差异较大,因此对比时应关注其变化趋势而非绝对值.YOLOv5 和 SSD 网络的训练损失下降速率远小于提出的模型和 Faster-RCNN(图 10).约在第 50 个训练周期,提出的模型和 Faster-RCNN 的训练损失趋于最低值,而 YOLOv5 和 SSD 在第 250 个训练周期时才趋于最低值.这表明在相同数据集下,提出的模型和 Faster-RCNN 具有更高的学习效率.此外,提出的模型在第 50 个训练周期后稳定,此后在 450 个训练周期中

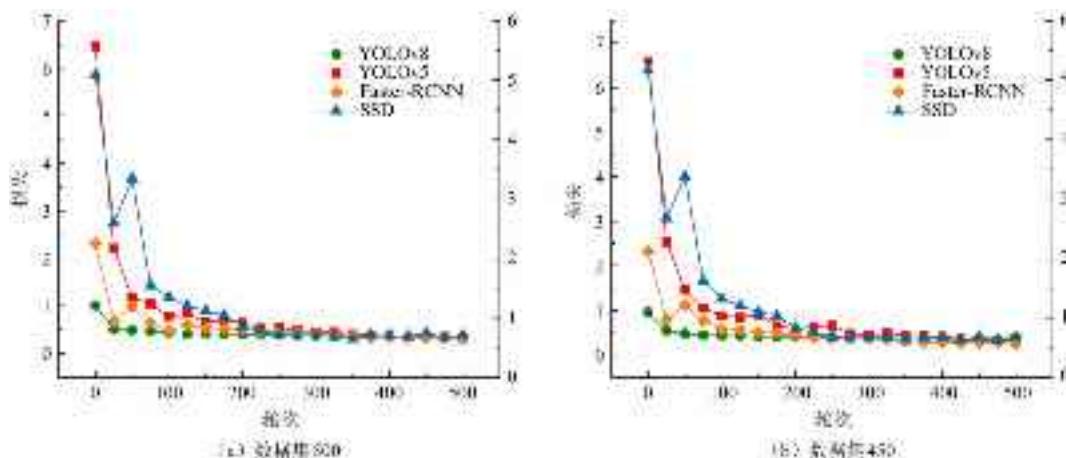


图 10 训练损失曲线对比
Fig.10 Comparison of training loss curves

损失缓慢下降且波动很小;而 Faster-RCNN 在第 55 个训练周期时发生较大波动,且后续波动幅度大于提出的模型,说明 Faster-RCNN 训练稳定性不如提出的模型,易出现过拟合。针对不同样本数量的数据集,SSD 和 YOLOv5 的损失曲线波动较大,稳定性低;而提出的模型和 Faster-RCNN 受样本数量影响较小,损失曲线波动较小,稳定性高。

螺栓锈蚀检测定义为二分类问题,即包括未锈蚀螺栓和锈蚀螺栓正例和负例。由于数据集来源于现场桥梁检测项目的实拍图片,锈蚀和未锈蚀螺栓的数量差距较大,导致数据集不平衡,即正、负样本数量差异大。因此,精准度指标可能会对网络模型性能造成过高估计,不适合作为模型评价指标。然而,通过对比多个网络模型的精准度及其曲线趋势,仍可以进行纵向评价。从图 11 可以看出,提出模型的精准度为 0.80~0.95,略低于 YOLOv5,但其随数据集样本数量变化产生的震荡较小,并能更快达到较高的精准度,说明提出的模型对数据集样本数量的敏感性较低,训练速度快,在样本数量不足和实际检测项目要求下效果更好。SSD 和 Faster-RCNN 的精准度远低于提出的模型和 YOLOv5。

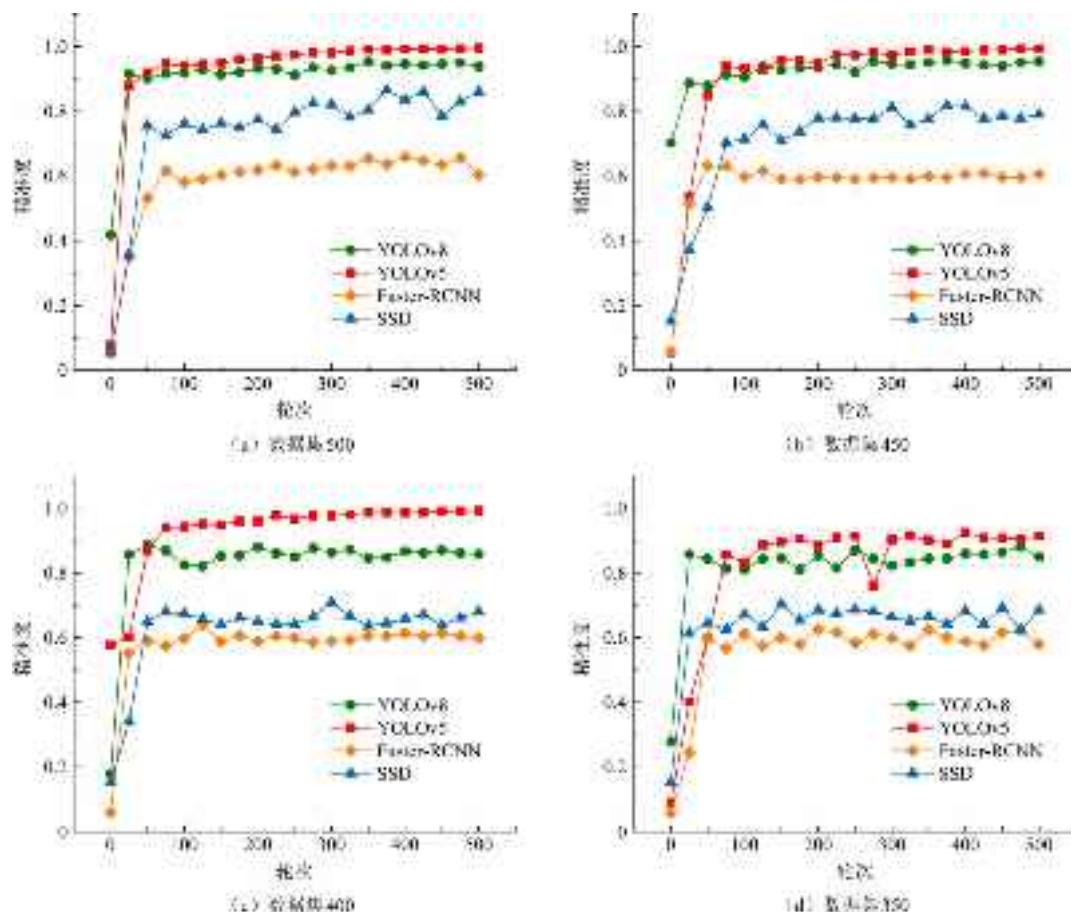


图 11 精准度曲线对比

Fig.11 Comparison of precision curves

在实际的钢桁架桥梁表观螺栓锈蚀病害检测中,受地理和交通条件限制,往往只能远距离拍摄,进而导致待检测的螺栓目标过小。为了验证模型能否识别到全部病害,采用召回率评估模型的查全能力。当数据集样本数量在 400 及以上时,YOLOv5 的召回率值稍大于提出的模型,且震荡幅度更小(图 12);当数据集样本数量小于 400 时,提出的模型的召回率值大幅超过 YOLOv5,且 YOLOv5 的召回率震荡幅度随着样本数量减少而增大,这再次证明提出的模型在样本数量较少情况下的优越性。提出的模型和 YOLOv5 的召回率在 4 个数据集上均大于 0.8,Faster-RCNN 和 SSD 的召回率均大于 0.6,验证了基于深度学习的桥梁表观螺栓病害识别的可靠性。

在训练结束后进行测试,得到平均精度(mAP)指标,其中,IoU 为 50 时的 mAP50 结果如图 13 所示。在相

同样本数量的数据集情况下, Faster-RCNN 的 mAP50 指标最高约为 0.64, 显著低于其他 3 个网络的 mAP50 指标。这表明对于钢桁架桥梁表观螺栓锈蚀病害识别, Faster-RCNN 网络的检测效果较差。在相同数据集情况下提出的模型和 YOLOv5 的 mAP50 指标差别较小, 但提出的模型能更快达到稳定的 mAP50 值, 显示出更高的训练效率。

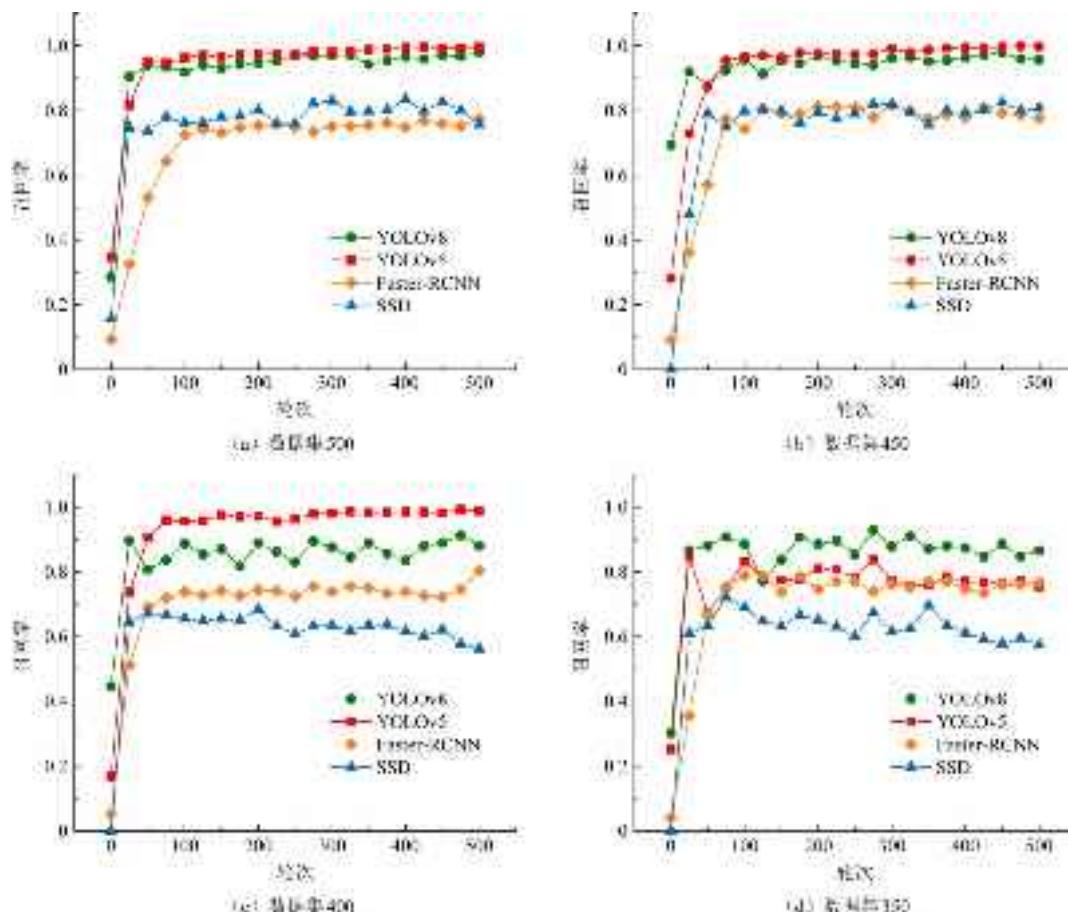


图 12 召回率曲线对比

Fig.12 Comparison of recall curves

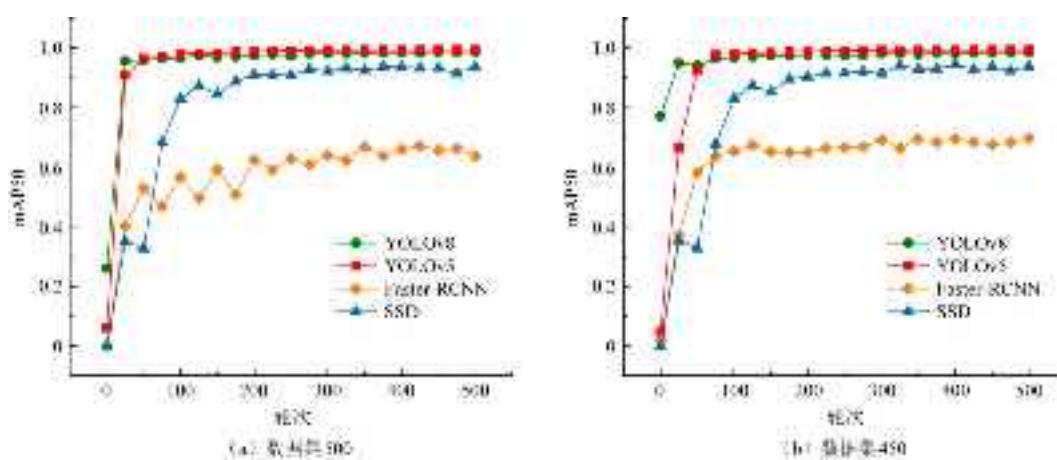


图 13 mAP50 曲线对比

Fig.13 Comparison of mAP50 curves

2.4.3 识别结果可视化

螺栓检测结果可视化是使用经过训练的模型对陌生的病害图片进行识别, 并将

检测结果可视,从而实现对模型检测效果的可视化评价。使用上述模型对不同场景下3张螺栓图片进行病害检测,检测的可视化结果如图14所示。由于螺栓分布较为密集,如果将每个螺栓的置信度结果都在图片上进行可视化,会导致检测结果图片内容混乱。因此,仅在第1幅和第2幅图中展示置信度标签,在第3幅图中仅展示预测框。

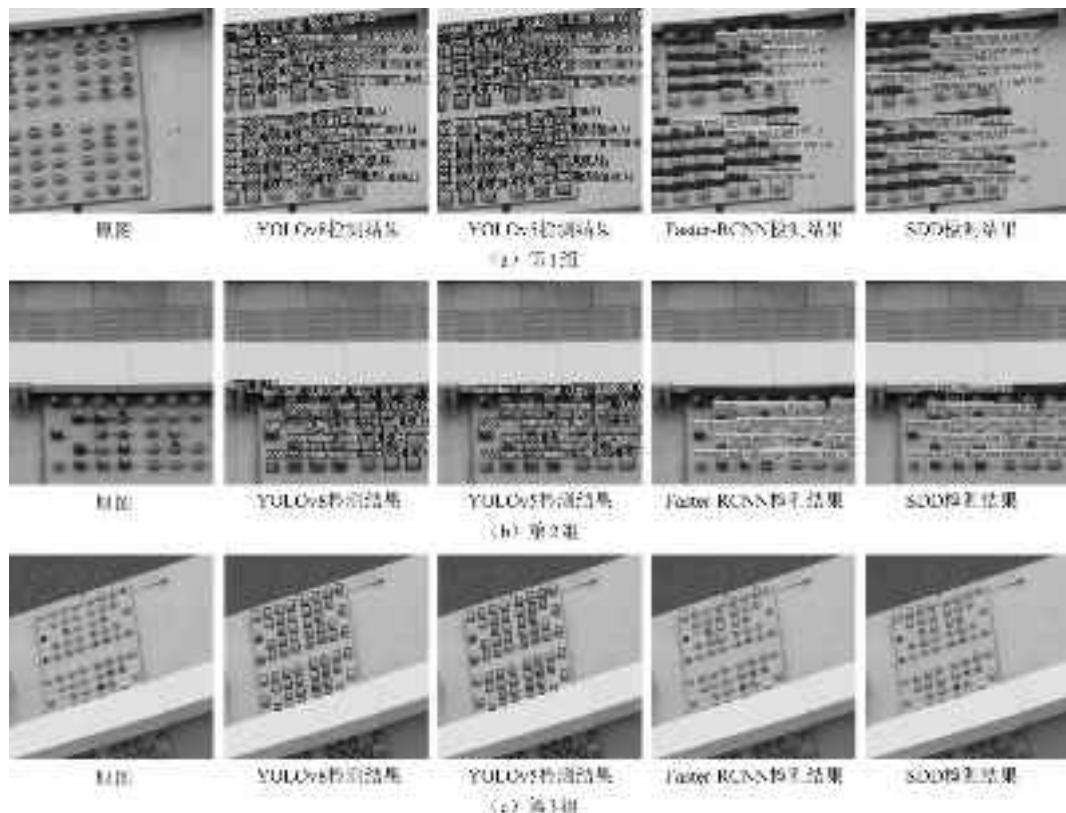


图14 可视化结果对比

Fig.14 Comparison of visualisation results

第1组图片(图14(a))中,提出的模型未出现漏检和误检情况;YOLOv5无漏检,但将5颗锈蚀螺栓误检为正常,将3颗正常螺栓误检为锈蚀;Faster-RCNN漏检5颗螺栓,将6颗锈蚀螺栓误检为正常,无正常螺栓误检为锈蚀;SSD无漏检,将3颗锈蚀螺栓误检为正常,2颗正常螺栓误检为锈蚀。

第2组图片(图14(b))中,提出的模型漏检1颗螺栓,无误检;YOLOv5无漏检,将5颗锈蚀螺栓误检为正常,且1次将劣化涂层误检为正常螺栓;Faster-RCNN无漏检,将3颗锈蚀螺栓误检为正常,无正常螺栓误检为锈蚀;SSD无漏检,将1颗锈蚀螺栓误检为正常,1颗正常螺栓误检为锈蚀。

第3组图片(图14(c))中,螺栓目标较小,提出的模型保持高完检率和低误检率;YOLOv5无漏检,仅有1颗锈蚀螺栓误检为正常,误检率大幅降低;Faster-RCNN和SSD均出现较高漏检率,病害定位效果不如提出的模型和YOLOv5。

综上所述,提出的模型检测精度高,完检率高,误检率低,实现了针对螺栓目标检测任务可靠应用。

2.4.4 错误分析

如图15所示,在实际的病害检查过程中发现了错误识别,分析原因如下:

(1)置信度低。部分图片的检测识别结果置信度较低,这种过低的置信度会影响目标类别识别的准确性,从而出现模型误判;

(2)目标遗漏。由于待识别目标相对于整体图像的比例过小,这使得模型对于该较小区域内病害目标的识别遗漏;

(3)目标框偏差。部分图片中的目标框包含了过多的非目标信息或未能包含全部目标,进而导致检测结果的误差。



图 15 识别结果展示

Fig.15 Shows for the identification results

通过对比分析,总结原因如下:

(1)图像质量差异.此次使用的图像数据来自多次无人机航拍,可能由于采集方法的不统一,导致了图像质量的参差不齐,即存在大量干扰和噪声信息.这会影响模型的识别精度.

(2)标注误差.在进行图像标注时,部分图像因清晰度不高或拍摄角度限制,导致无法对其类别进行准确标注.这种标注误差使得模型的训练过程中存在大量不确定性.

(3)样本的低多样性.训练使用图像多样性一般,对于一个多目标分类任务,多角度、多场景、多环境下的病害图像对于识别性能很关键.单一的样本较难让模型识别复杂工况下的螺栓病害.

(4)螺栓边缘模糊.清晰图像的识别效果明显优于模糊图像.由于螺栓边缘模糊,导致干扰因素增多,螺栓边界难以辨别.此外,螺栓目标较小,也进一步增加了识别难度.

(5)模型自身局限.尽管提出的模型每个格子可以预测 3 个边界框,但最终仅选择 IOU 最高的边界框作为检测输出.因此,每个格子最多只能预测 1 个病害.

针对螺栓锈蚀识别存在的置信度低、目标框偏差、小目标遗漏和病害类别输出单一等问题,做出以下改进:考虑通过图像增强技术,增加可用于训练样本的多样性,进而提升模型对各种病害情况的鲁棒性;改进标注质量和后处理方法优化目标框;采用多尺度训练和特征金字塔网络解决小目标遗漏;引入多标签分类和语义分割模型处理病害类别输出单一的问题.此外,提高图像质量和标注精度、使用图像超分辨率技术解决图像质量差和标注误差大的问题.最后,尝试使用多模态大模型技术,进一步提升识别效果和稳定性.

2.5 螺栓病害可视化定位结果

为验证病害可视化方法的实用性,选择拼接图像文件共计 72 张.由于一次性处理大批量图片会出现拼接异常、耗时过长等问题,因此,需先通过实验找到在满足高精确度和高效率的条件下针对病害图像的一次图像拼接任务所能处理的最大张数,然后对其分批处理的结果图片进行二次拼接,形成完整的全景图片.拍摄的桥梁左桁架顶面 72 张图片,按照飞行拍摄路线对 72 张图片进行排列,并对其进行从 1~72 进行编号,编号 1~24 为第 1 组,编号 25~48 为第 2 组,编号 49~72 为第 3 组.编号分组完成后进行每组图像拼接操作.3 个图片拼接任务结束后会得到桥梁左桁架顶面的 3 张局部拼接图,对其进行二次拼接操作,最终得到桥梁左桁架顶面全景图(图 16).由于全景图过长,如果缩小展示会导致图片的不清晰,因此分段展示.

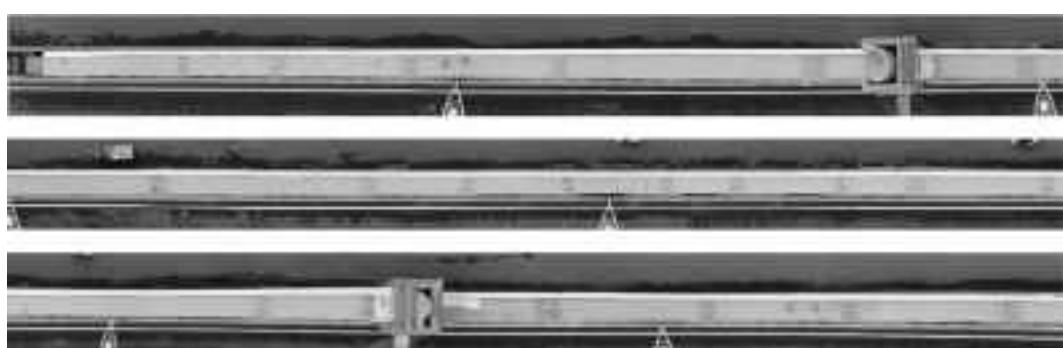


图 16 拼接结果展示

Fig.16 Shows for the splicing results

基于无人机拍摄图像对桥梁进行倾斜摄影建模,输出展示在真实地图上,导入无人机所拍摄的图像,并且能根据图像的 GPS 信息自动将图像定位至三维地图中进行展示。考虑规划可覆盖此次拍摄主体的航线,借助 DJITerra 软件实现。此次倾斜摄影模型数据采集选用大疆 M300RTK 型无人机,飞行高度为 40m,为保证相邻图像间的重叠率,图像拍摄间隔设置为 2s,飞行时长共 41min22s,共计拍摄图像 484 张。利用无人机对桥梁图像采集完成后,进行桥梁倾斜摄影模型的建立。三维重建后的结果如图 17 所示。

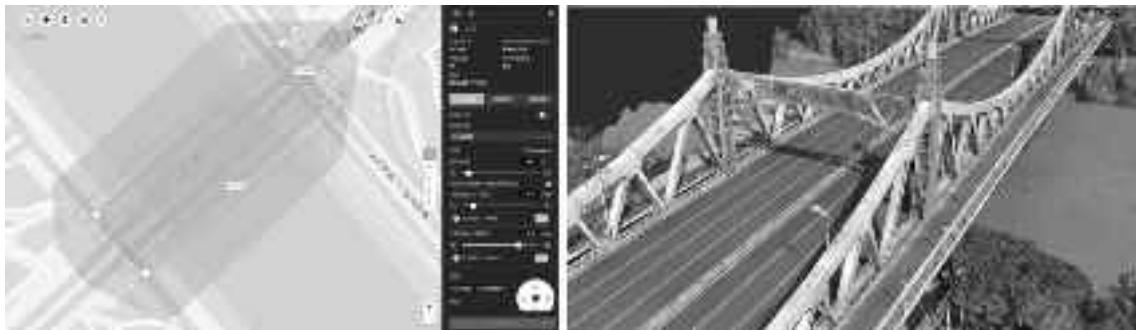


图 17 规划航线和倾斜摄影模型

Fig.17 Plotting routes and tilt-shot modelling

利用提出的图像 GPS 信息处理方法,将原图像 GPS 信息进行批量提取,并批量融合到识别结果图像中,实现桥梁螺栓锈蚀病害三维空间位置的可视化。首先,对原图像 GPS 信息进行批量提取,并将提取的 GPS 信息保存为 CSV 格式文件;然后,对桥梁螺栓锈蚀病害识别结果图像进行编号,编号顺序和 GPS 信息表中的编号顺序保持一致且一一对应;继之,将桥梁螺栓锈蚀病害识别结果图像文件夹与 GPS 信息表导入软件中,进行定位信息融合;最后,将坐标融合完成的包含原图 GPS 信息的桥梁螺栓锈蚀病害识别结果图像导入软件,点击相应坐标点,即可查看相对应图像的病害识别结果(图 18)。



图 18 病害图像定位

Fig.18 Damage image positioning

3 结论

基于无人机提出一种深度学习的小样本桥梁螺栓病害识别算法,并结合桥梁数字化倾斜摄影模型实现了螺栓病害的可视化定位,以某城市钢桁架桥为例进行了实验验证,得出主要结论如下:

(1) 提出基于 YOLOv8 的改进方法,通过增加小目标检测层、Focus 层、Bottleneck CSP 模块实现小样本学习目标,其算法精确度得到提高,最高可达 0.9013;

(2) 开展模型的对比研究,将所提模型与 SSD、YOLOv5 和 Faster-RCNN 这 3 个模型的性能对比结果表明,提出的模型在小样本情况下具有较好的识别性能,说明模型在实际应用中的价值;

(3) 提出的基于无人机定航定位功能的病害二维-三维可视化方法,利用图像 GPS 信息,建立三维映射关系。验证结果表明,该方法对于螺栓锈蚀病害的空间位置可视化具有较高精度,在桥梁检测领域具有良好的实用价值和应用前景;

(4) 该研究为桥梁可达性较差的高空构件日常检测提供了高效的数字化解决方案,保障了桥梁长效服役与安全耐久。

参考文献

- [1] 林涛,贾磊,董优,等.基于多属性效用的桥梁综合性能维养决策算法[J].应用基础与工程科学学报,2023,31(5):1278-1296
Lin Tao, Jia Lei, Dong You, et al. Bridge comprehensive performance maintenance decision-making algorithm based on multi-attribute utility [J]. Journal of Basic Science and Engineering, 2023, 31(5): 1278-1296
- [2] 钟新谷,彭雄,沈明燕.基于无人机成像的桥梁裂缝宽度识别可行性研究[J].土木工程学报,2019,52(4):52-61
Zhong Xingu, Peng Xiong, Shen Mingyan. Feasibility study on crack width identification of bridges based on UAV imaging [J]. Journal of Civil Engineering, 2019, 52(4): 52-61
- [3] 吴华勇,王枫,赵荣欣,等.基于无人机的桥梁表观病害快速采集与识别[J].城市道桥与防洪,2023,(11):99-101+318
Wu Huayong, Wang Feng, Zhao Rongxin, et al. Rapid collection and identification of bridge surface defects based on UAVs [J]. Urban Roads Bridges & Flood Control, 2023, (11): 99-101+318
- [4] 刘睿.基于无人机的桥梁病害检测系统研究[J].北方交通,2024,(1):17-20
Liu Rui. Research on bridge defect detection system based on UAVs [J]. Northern Traffic, 2024, (1): 17-20
- [5] 魏法胜,高亮,钟运平,等.基于无人机的曲线宽幅矮塔斜拉桥表观病害智能检测[J].公路,2023,68(10):155-160
Wei Fasheng, Gao Liang, Zhong Yunping, et al. Intelligent detection of surface defects in curved wide low-tower cable-stayed bridges based on UAVs [J]. Highway, 2023, 68 (10): 155-160
- [6] 邹露鹏,范钟倩.微型无人机在公路桥梁养护检测工程中的应用[J].公路,2017,62(7):172-175
Zou Lupeng, Fan Zhongqian. Application of micro UAVs in highway bridge maintenance and inspection engineering [J]. Highway, 2017, 62(7): 172-175
- [7] 冯东明,余星宇,黎剑安,等.基于无人机的悬索桥主缆自动巡检及小样本表观病害识别[J].中国公路学报,2024,37(2):29-39
Feng Dongming, Yu Xingyu, Li Jian'an, et al. Automatic inspection and small-sample surface defect identification of suspension bridge main cables based on UAVs [J]. China Journal of Highway and Transport, 2024, 37(2): 29-39
- [8] 余加勇,李锋,薛现凯,等.基于无人机及Mask R-CNN的桥梁结构裂缝智能识别[J].中国公路学报,2021,34(12):80-90
Yu Jiayong, Li Feng, Xue Xiankai, et al. Intelligent identification of bridge structure cracks based on UAVs and Mask R-CNN [J]. China Journal of Highway and Transport, 2021, 34(12): 80-90
- [9] Ye X W, Jin T, Li Z X, et al. Structural crack detection from benchmark data sets using pruned fully convolutional networks [J]. Journal of Structural Engineering, 2021, 147(11):04721008
- [10] 阳茜汕,卓德兵.基于无人机与深度学习的钢桁架结构螺栓脱落智能检测研究[J].中国水运,2023,(5):153-155
Yang Qianshan, Zhuo Debing. Intelligent detection of bolt loss in steel truss structures based on UAVs and deep learning [J]. China Water Transport, 2023, (5): 153-155
- [11] 沈浩,江臣,陈宇文,等.基于深度学习的钢桁架桥螺栓病害智能识别方法[J].南京工业大学学报(自然科学版),2020,42(5):608-615
Shen Hao, Jiang Chen, Chen Yuwen, et al. Intelligent identification method for bolt defects in steel truss bridges based on deep learning [J]. Journal of Nanjing University of Technology (Natural Science Edition), 2020, 42(5): 608-615
- [12] 房志恒.钢桁梁桥螺栓脱落病害定位和定量识别方法研究[D].北京:北京交通大学,2020
Fang Zhiheng. Research on positioning and quantitative identification methods of bolt loss in steel truss bridges [D]. Beijing: Beijing Jiaotong University, 2020
- [13] Xu Y, Wei S Y, Bao Y Q, et al. Automatic seismic damage identification of reinforced concrete columns from images by a region-based deep convolutional neural network [J]. Structural Control & Health Monitoring, 2019, 26(3):e2313
- [14] 王海群,王炳楠,葛超.重参数化YOLOv8路面病害检测算法[J].计算机工程与应用,2024,60(5):191-199
Wang Haiqun, Wang Bingnan, Ge Chao. Re-parameterized YOLOv8 algorithm for pavement defect detection [J]. Computer Engineering and Applications, 2024, 60(5): 191-199
- [15] Chen R L. Migration learning-based bridge structure damage detection algorithm [J]. Scientific Programming, 2021, 2021(1):1102521
- [16] Dung C V, Sekiya H, Hirano S, et al. A vision-based method for crack detection in gusset plate welded joints of steel bridges using deep convolutional neural networks [J]. Automation in Construction, 2019, 102:217-229
- [17] Yu Z W, Shen Y G, Shen C K. A real-time detection approach for bridge cracks based on YOLOv4-FPM [J]. Automation in Construction, 2021, 122:103514
- [18] 柴雪松,朱兴永,李健超,等.基于深度卷积神经网络的隧道衬砌裂缝识别算法[J].铁道建筑,2018,58(6):60-65
Chai Xuesong, Zhu Xingyong, Li Jianchao, et al. Tunnel lining crack identification algorithm based on deep convolutional neural network [J]. Railway Construction, 2018, 58(6): 60-65
- [19] 陈金桥.基于无人机图像的混凝土桥梁表观病害识别研究[D].南京:东南大学,2020
Chen Jinqiao. Research on surface defect identification of concrete bridges based on UAV images [D]. Nanjing: Southeast University, 2020
- [20] 王林.基于YOLO的改进目标检测算法研究[D].无锡:江南大学,2020
Wang Lin. Research on improved object detection algorithm based on YOLO [D]. Wuxi: Jiangnan University, 2020
- [21] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection [C]. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016

- [22] 王晨灿,李明.基于 YOLOv8 的火灾烟雾检测算法研究[J].北京联合大学学报,2023,37(5):69-77
Wang Chencan,Li Ming.Research on fire smoke detection algorithm based on YOLOv8[J].Journal of Beijing Union University ,2023,37(5):69-77
- [23] 封亚伟.基于无人机平台的钢桥铆钉病害全场智能检测方法研究[D].哈尔滨:哈尔滨工业大学,2021
Feng Yawei.Research on intelligent detection method of rivet defects in steel bridges based on UAV platform[D].Harbin: Harbin Institute of Technology ,2021
- [24] 杨占龙.基于特征点的图像配准与拼接技术研究[D].西安:西安电子科技大学,2008
Yang Zhanlong.Research on image registration and stitching technology based on feature points[D].Xi'an:Xidian University ,2008
- [25] 韩露.面向智能移动监控辅助的可穿戴视觉研究[D].重庆:重庆大学,2011
Han Lu.Wearable vision research for intelligent mobile monitoring assistance[D].Chongqing:Chongqing University ,2011
- [26] 毛琳,王超,余星宇,等.基于无人机倾斜摄影的桥梁三维建模研究[J].港工技术,2022,59(6):58-62
Mao Lin,Wang Chao,Yu Xingyu, et al. Research on 3D modeling of bridges based on UAV oblique photography [J]. Harbor Engineering Technology ,2022,59 (6):58-62
- [27] 李炜,刘耕,葛云峰,等.基于深度学习的钻孔图像岩体结构面识别[J].应用基础与工程科学学报,2024,32(3):702-720
Li Wei,Liu Geng,Ge Yunfeng, et al.Identification of rock mass structural planes in borehole images based on deep learning[J].Journal of Basic Science and Engineering ,2024,32(3):702-720

Rapid Identification and Visual Localization Method for Few-Shot Inspection of Bolt Defects in Bridge Tall Components

ZHU Yanjie, CHEN Taoyu, WANG Yuchen, XIONG Wen

(Department of Bridge Engineering, School of Transportation, Southeast University, Nanjing 210096, China)

Abstract

To enhance the efficiency of bridge tall component inspections and achieve rapid detection and accurate localization of defects, this study proposed a few-shot inspection algorithm for bridge bolt corrosion using Unmanned Aerial Vehicle (UAV) imagery and deep learning techniques. UAVs were employed to capture images of hard-to-reach areas by flying along a customized low-altitude path. This path was specifically designed to collect visual data at fixed angles, distances, and postures, ensuring the temporal consistency necessary for analysis. The study developed a corrosion detection method for bridge bolts based on the You Only Look Once version 8 (YOLOv8), tailored for few-shot datasets. Comparative experiments with multiple baseline models demonstrate that the proposed approach achieves superior performance, with an accuracy exceeding 90%, even with limited annotated sample numbers. Combining the collected image data with a digital model of the bridge enabled the precise visualization and localization of bolt defects in three-dimensional space. This method offers an efficient solution for the maintenance and inspection of difficult-to-reach bridge tall components, contributing to the long-term durability and safety of bridge structures.

Keywords: bridge engineering; digital bridges; bridge tall component; bolt corrosion; defect identification; few-shot learning; UAV; visual localization